

Household Energy Consumption

Анализ и прогноз потребления электроэнергии · тема №4, Cluster 1

Rabat Karabek, Nurmukhanbet Sanzhar, Ussurbayeva Inkar — AAI-2603M

Programming for Data Analysis and Database

Задача и данные

Цель: найти суточные, недельные и сезонные паттерны нагрузки и пики, сравнить прогноз с baseline

2,07 млн
поминутных записей, 127 МБ

47 мес.
12.2006 – 11.2010, Co (Франция)

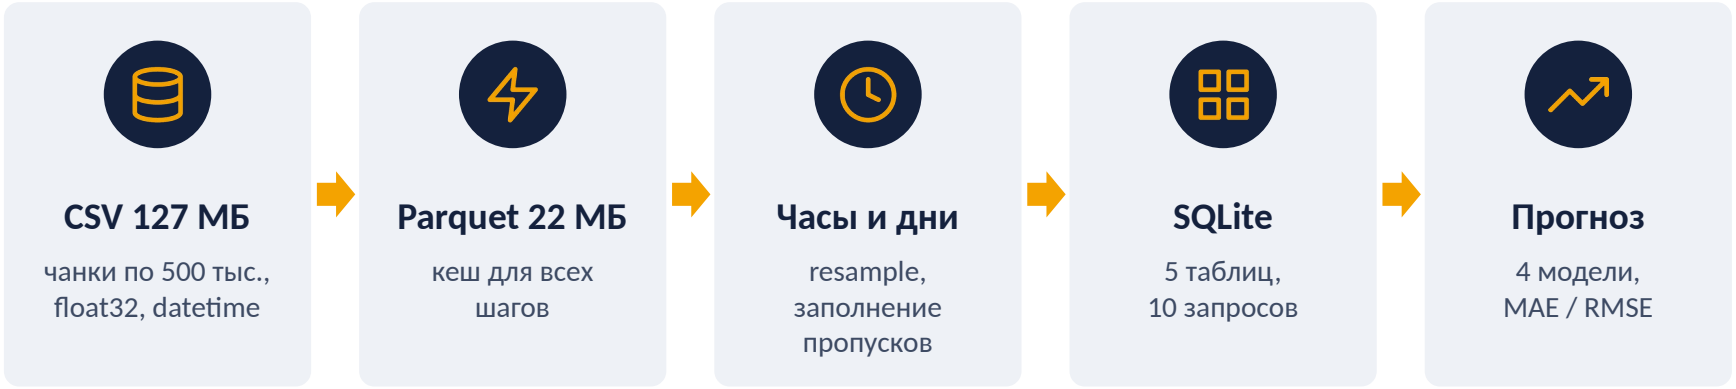
7
признаков: мощность, U, I, 3 подсчётчика

1,25 %
пропусков (сбои счётчика)

Источник: UCI Individual Household Electric Power Consumption

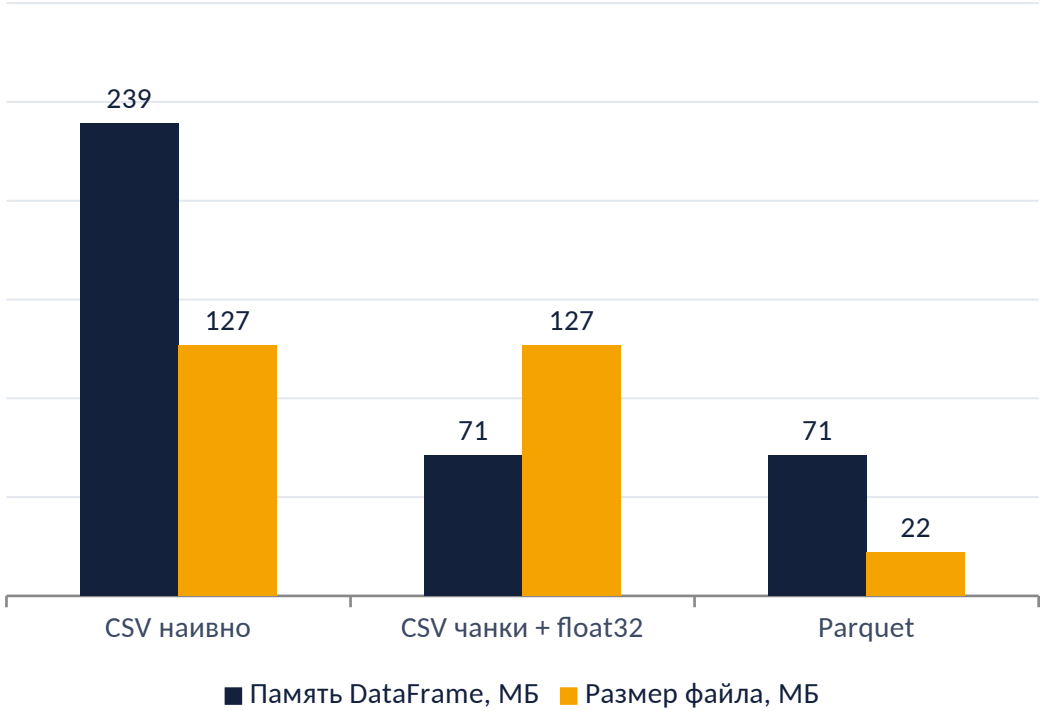
- Sub_metering_1 — кухня, Sub_metering_2 — прачечная, Sub_metering_3 — бойлер и кондиционер
- Python 3.11 · pandas, pyarrow, statsmodels, scikit-learn, SQLite, Plotly, Streamlit, JupyterLab

Архитектура: от CSV до прогноза



Точки входа: analysis.ipynb (JupyterLab) · main.py (консольное меню) · dashboard.py (Streamlit). Логика — 8 модулей src/*.py, 80 функций, 10 тестов pytest

Parquet: в 5,8 раза меньше, чтение ~0,1 с



- Наивное чтение: всё становится строками из-за «?» — 239 МБ, считать нельзя
- Чанки + float32: 71 МБ (в 3,4 раза меньше), ~2 с
- Parquet: 22 МБ на диске, ~0,1 с, пиковая память ≈ 250–300 МБ против ≈ 600 МБ
- Вывод: CSV читаем один раз, дальше работаем с Parquet

Пропуски: 3,7 % в 2010 году, до 120 ч подряд



Выбросы не удаляем

пики мощности — реальные включения бойлера и духовки, их и анализируем

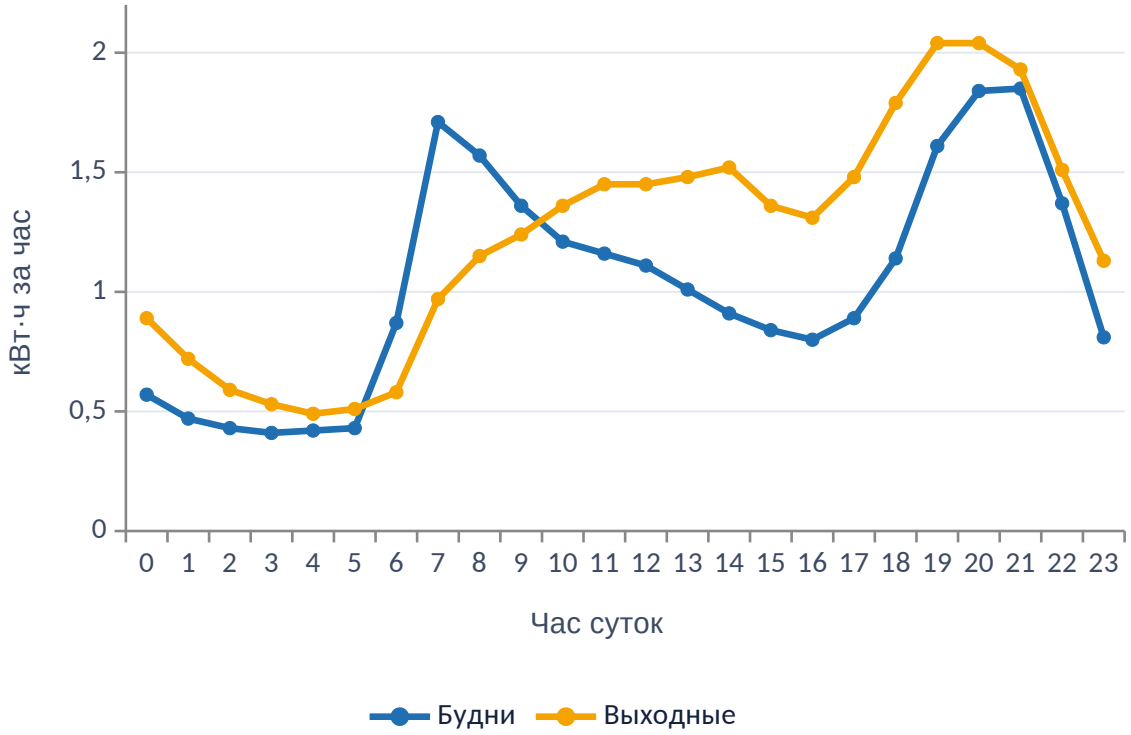
Пропуски ≤ 3 ч

линейная интерполяция по времени

Длинные пропуски

тот же час неделей раньше — сохраняет суточный профиль

Будни — два пика, выходные — один, выше



1,71 и 1,85

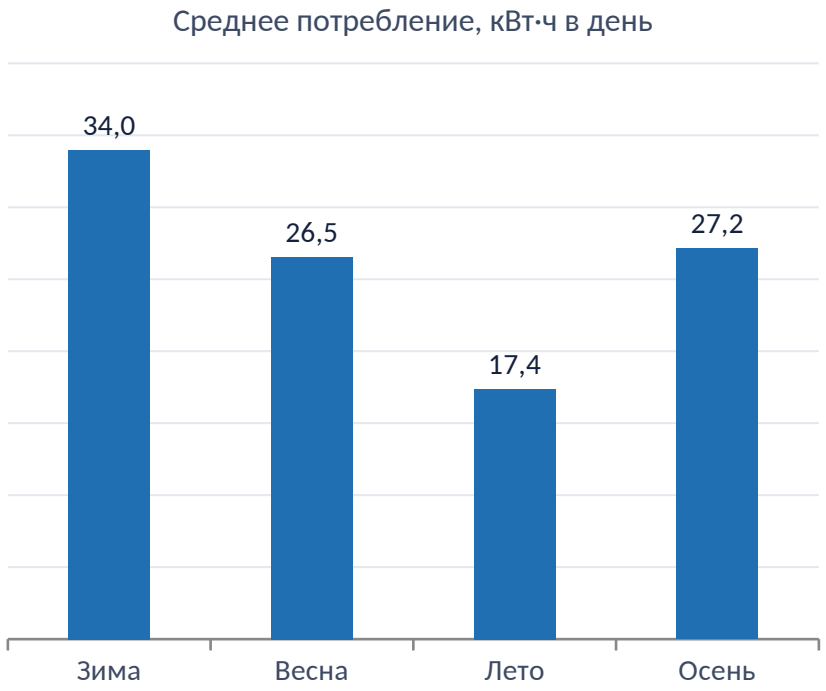
пики будней в 7 ч и 21 ч, кВт·ч

2,04

пик выходных в 19–20 ч, кВт·ч

Ночной минимум 3–5 ч ≈ 0,42 — фон холодильника и дежурных приборов

Зима вдвое выше лета



1 730

пиковых часов (≥ 2,86 кВт·ч, верхние 5 %)

47 %

пиков — в выходные (Сб 411, Вс 409)

47 %

пиков — зимой, летом лишь 5 %

19–21 ч

самые частые часы пиков

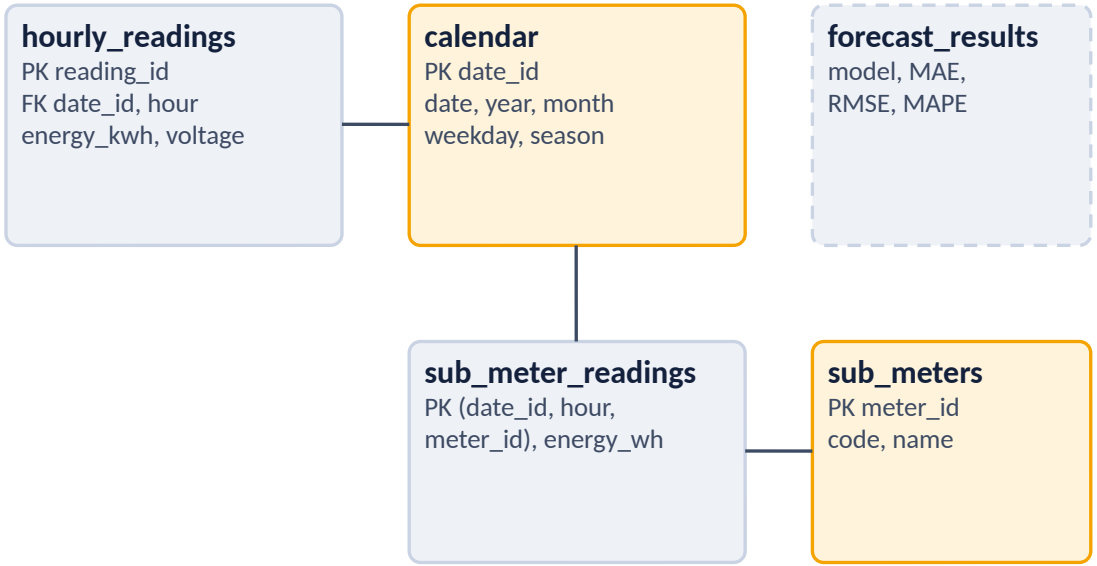
STL (период 7 дней): недельная компонента слабее шума (ст. откл. 4,3 против 5,5 кВт·ч). Годовой тренд почти плоский: 26,8 → 25,3 кВт·ч/день

Половина энергии — вне подсчётчиков



- Бойлер и кондиционер — главный измеряемый потребитель: 35,5 %, летом до 39 %
- Энергия ≈ сила тока: r = 0,999 (P = U × I)
- С напряжением связь обратная: r = −0,38 — при большой нагрузке напряжение проседает
- Корреляция с общей нагрузкой: прочее 0,76, бойлер 0,70, кухня 0,50, прачечная 0,44

SQLite: 5 таблиц, 10 аналитических запросов

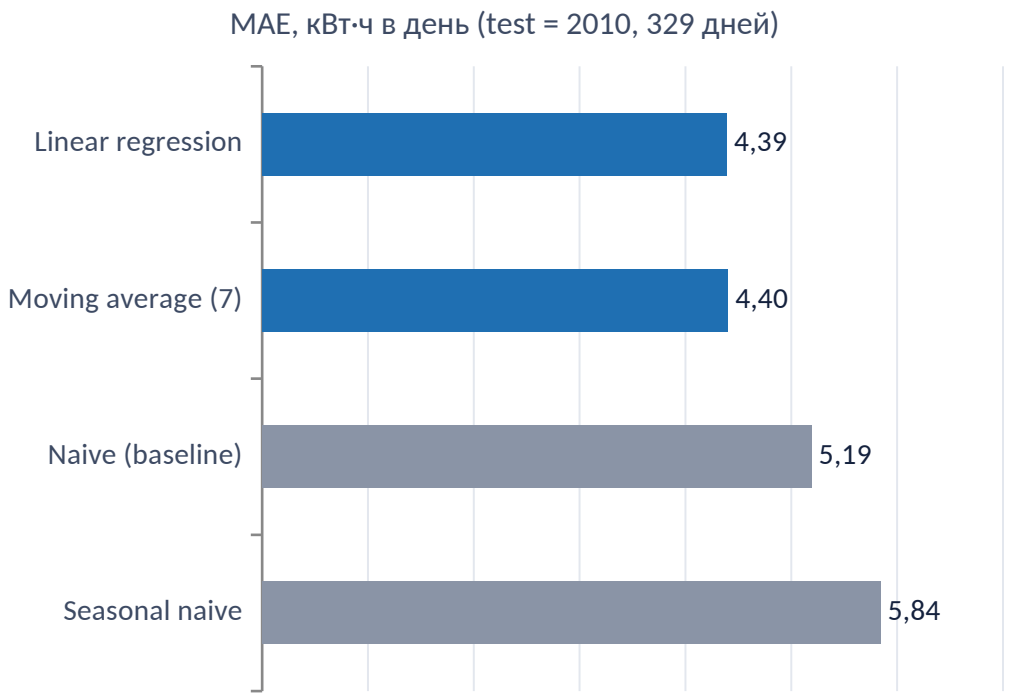


Жёлтые — измерения, серые — факты; связи 1 : N

Конструкция	Запросы
JOIN, GROUP BY	1, 3, 4
HAVING + подзапрос	2, 7, 8
CTE (WITH)	5–8, 10
Оконные: SUM, AVG, RANK, LAG, NTILE	4, 6, 7, 8, 10
Коррелированный подзапрос	9

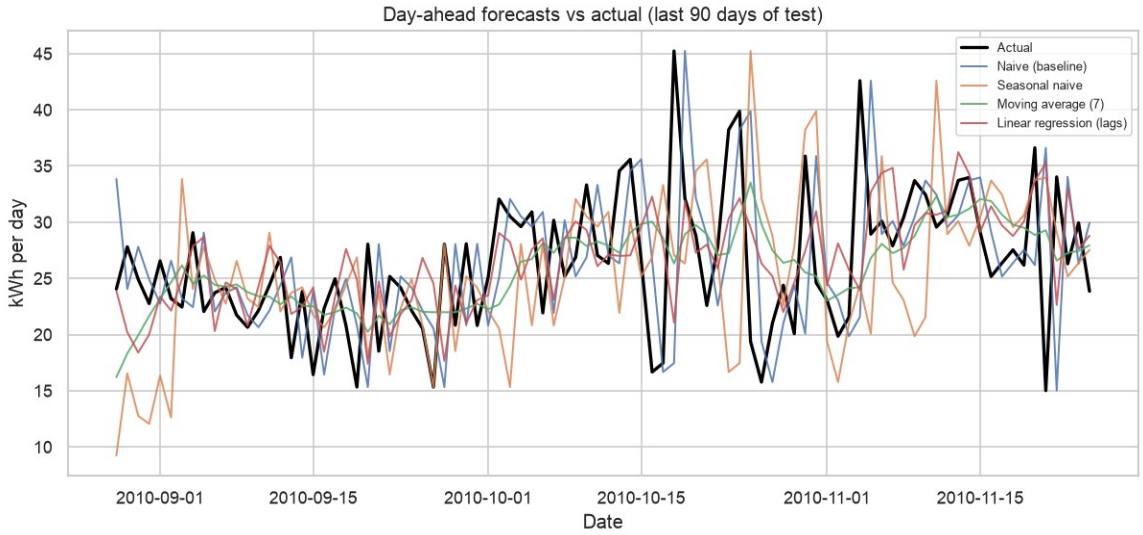
Результаты — в Pandas через pd.read_sql_query

Регрессия и MA(7) точнее baseline на 15 %



- Train 12.2006–2009, test 2010 — хронологически, без перемешивания
- Признаки регрессии только из прошлого: лаги 1, 2, 3, 7, 14, средние 7 и 28 дней, день недели, месяц
- Seasonal naive хуже baseline: недельный ритм слабее дневного шума
- MA(7) — 0,6 мс, регрессия — 30 мс

Прогноз против факта, осень 2010



- Летом лучший — naive: потребление ровное
- Зимой и осенью выигрывает регрессия
- Крупные ошибки — резкие всплески до 45 кВт·ч, их не предсказать без погоды
- Почасовой прогноз: регрессия MAE 0,363 против 0,407 у naive (−11 %)

Выбор подхода

Суточный прогноз → MA(7)

- MAE 4,40 — как у регрессии
- без обучения
- в 50 раз быстрее, в 17 раз меньше памяти

Почасовой и на N дней → регрессия

- учитывает час, день недели, месяц
- единственная лучше naive на часах
- можно добавить погоду и праздники

Данные → Parquet + SQLite

- Parquet — быстрый кеш для анализа
- SQLite — агрегаты, окна, дашборд
- CSV читается один раз

Демонстрация: меню и дашборд

`python main.py`

1 Загрузка и аудит
2 Построить SQLite
3 SQL-запрос
4 Профили и пики
5 Сравнение моделей
6 Прогноз на N дней
7 Статистика за период
8 CSV vs Parquet

try/except на вводе, история в menu_state.json

`streamlit run dashboard.py`

- Фильтры: год, сезон, будни/выходные, подсчётчик
- KPI: дни, среднее и максимум за день, пиковый час
- Вкладки: тренд, профили, подсчётчики, прогноз
- Прогноз на 1–30 дней вперёд

Выводы

- Parquet + float32: память ÷ 3,4, файл ÷ 5,8
- Пики: зимние вечера и выходные, 19–21 ч
- Зима 34,0 против лета 17,4 кВт·ч в день
- MA(7) и регрессия на 15 % лучше baseline

Вклад участников

Участник	Вклад
Rabat Karabek	
Nurmukhanbet Sanzhar	
Ussurbayeva Inkar	

Код: GitHub · отчёт и презентация: LMS Moodle